

Отчет об экспериментах (Д31 MLOps)

Размер обучающей выборки


Гипотеза: качество модели классификации растет с увеличением наблюдений в обучающей выборке

Параметр: размер тренировочного датасета

Для проверки гипотезы параметр изменялся по следующим значениям: 1000, 10000, 22972 (весь тренировочный датасет).

Модель и ее гиперпараметры были зафиксированы: логистическая регрессия, `penalty='l2'`, `C=0.9`, `solver='lbfgs'`, `max_iter=1000`.

Метрика ROC-AUC в зависимости от размера тренировочной выборки (размер тренировочной выборки по оси Y указан в префиксе):



Метрика изменялась незначительно, но с наименьшим объемом тренировочного датасета получено наихудшее значение ROC-AUC.


Гиперпараметры логистической регрессии

Гипотеза: от параметра регуляризации зависит качество модели на тестовой выборке (при адекватных значениях, не слишком маленьких или слишком больших, качество выше)

Параметр: C (inverse of regularization strength)

Параметр изменялся по сетке: 0.001, 0.01, 0.1, 0.5, 0.99.

Метрика ROC-AUC при разных запусках:



Значительных изменений в метрике нет, сложно судить о верности гипотезы. Скорее всего, необходимо повторить эксперимент с более широкой сеткой значений.


Сравнение моделей

Гипотеза: дерево решений покажет качество лучше, чем логистическая регрессия, благодаря обнаружению нелинейных зависимостей


Параметр: тип модели

Параметр имел два значения: логистическая регрессия и дерево решений. Сравнивались между собой несколько запусков с лучшими гиперпараметры для этих моделей.

ROC-AUC:



F1-score:



Гипотеза подтверждается, дерево решений превосходит по метрикам логистическую регрессию.

Гиперпараметры дерева решений


Гипотеза: качество модели будет лучше с увеличением глубины дерева до определенного порога, после которого модель будет переобучена

Параметр: глубина дерева


Глубина дерева менялась по сетке от 2 до 8 с шагом 1.

Метрики представлены на графиках ниже.

ROC-AUC:



F1:



С увеличением глубины дерева действительно наблюдается рост метрик качества. Однако не было достигнуто глубины, при которой дерево переобучается.

Лучшая модель

В результате серии экспериментов лучше моделью оказалось дерево решений с глубиной 8.

Ссылка на запуск:

<http://158.160.2.37:5000/#/experiments/7/runs/05f8180af1b14246920992a41140bd3b>